

# Inteligencia Artificial

## Programa de Ingeniería de Sistemas

Tema: Agentes basados en la Incertidumbre - Redes Bayesianas (Regla de la Cadena)





# Redes Bayesianas

## Modelación

### Modelos

Representación simplificada de la realidad.

### Características

- ✿ Suficientemente simple para no complicar el análisis del sistema.
- ✿ Suficientemente completo para englobar la mayor parte del sistema.



# Redes Bayesianas

## Modelación

### Tipos de Modelos

Existen diferentes formas de representar los sistemas a través de modelos:

- ✿ **Matemáticos (analíticos)**

A través de funciones matemáticas que describan la dinámica de los sistemas.

- ✿ **Diagramas de Bloques**

Síntesis de las partes que componen al sistema.

- ✿ **Grafos**

Diagramas de representación simbólica sobre las relaciones existentes en un sistema.

- ✿ **Híbridos**

Varios tipos de modelos que en conjunto representan un sistema.



# Redes Bayesianas

## Algoritmos de Modelado

Englobados dentro de aprendizaje máquina (***Machine Learning***) permiten llevar a cabo problemas de aproximación y clasificación.

### Clasificación

- ✿ Paramétricos
- ✿ Probabilísticos
- ✿ Multivariados
- ✿ Bio-inspirados



# Redes Bayesianas

## Algoritmos de Modelado

Englobados dentro de aprendizaje máquina (*Machine Learning*) permiten llevar a cabo problemas de aproximación y clasificación.

### Clasificación

- ✿ Clasificador Bayesiano Naive
- ✿ **Redes Bayesianas**



# Redes Bayesianas

## Algoritmos de Modelado

Algunos algoritmos de modelado:

- ✿ Regresión
- ✿ Redes Neuronales Artificiales
- ✿ **Redes Bayesianas**
- ✿ Lógica Difusa
- ✿ Redes Orgánicas Artificiales



# Redes Bayesianas

## Introducción

Dado un conjunto de registros en una base de datos, donde cada registro pertenece a una clase, construir un modelo que permita predecir la clase de un nuevo registro.

# Redes Bayesianas

## Introducción

Redes Bayesianas se aplican en casos de incertidumbre a la hora de hacer cálculos de probabilidades condicionales y cálculo probabilidades desconocidas, dadas las condiciones específicas.

Aplicaciones: la bioinformática y la medicina, la ingeniería, clasificación de documentos, procesamiento de imágenes, la fusión de datos, y apoyar los sistemas de decisión, etc.

### Ejemplos:

- Inferencia:  $P(\text{Diagnóstico} \mid \text{Síntoma})$
- Detección de anomalías: ¿Es esta observación anómala?
- Recolección de datos: ¿Cuál es la próxima prueba de diagnóstico dado en un conjunto de observaciones?





# Redes Bayesianas


## La intuición detrás de Probabilidades

Intuitivamente, la probabilidad del evento  $A$  es igual a la porción de los resultados en donde  $A$  es cierto.

$\Omega$  es el conjunto de todos los resultados posibles. Su superficie es de  $P(\Omega) = 1$

El conjunto de color naranja corresponde a los resultados en donde  $A$  es verdadera

$P(A) = \text{Área del óvalo naranja}$ . Es evidente que  $0 \leq P(A) \leq 1$





# Redes Bayesianas

## Axiomas de Probabilidad de Kolmogorov

*“La teoría de la probabilidad como una disciplina matemática, puede y debería ser desarrollada a partir de axiomas exactamente del mismo modo como la geometría y el álgebra”.*

Andrey Nikolaevich Kolmogorov. Los fundamentos de la Teoría de la Probabilidad de 1933.



- 1  $P(A) \geq 0, \forall A \subset \Omega$
- 2  $P(\Omega) = 1$
- 3  $\sigma$ -aditividad. Cualquier secuencia numerable de sucesos disjuntos dos a dos  $A_1, A_2, \dots$   $P\left(\bigcup_i A_i\right) = \sum_i P(A_i)$



# Redes Bayesianas


## Consecuencias de los Axiomas

$$P(\bar{A}) = 1 - P(A). \quad \text{Donde } \bar{A} = \Omega - A$$

$$P(\emptyset) = 0$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

$$P(A) = P(A \cap B) + P(A \cap \bar{B})$$





# Redes Bayesianas

## Probabilidad Conjunta

Es la probabilidad de ocurrencia de dos o más eventos.

De la expresión

$$P(B|A) = \frac{P(A \cap B)}{P(A)}$$

Al despejar  $P(A \cap B)$ , se obtiene:  $P(B|A)P(A)$

Esta expresión es llamada **Ley de multiplicación de probabilidades**.


$P(A \cap B)$  recibe el nombre de **Probabilidad Conjunta** y corresponde a la probabilidad de que se presenten resultados comunes a los eventos A y B.

# Redes Bayesianas

# Probabilidad Condicional

$P(B|A)$  = Proporción del espacio en el que  $B$  es verdad, dado que  $A$  también es cierto.

Definición formal de Probabilidad Condicional:  $P(B|A) = \frac{P(A \cap B)}{P(A)}$





# Redes Bayesianas

## Independencia de Eventos

### Definición

Dos eventos  $A$  y  $B$  son **independientes** si y solo si

$$P(A \cap B) = P(A)P(B)$$

Notación:  $I(A, B)$ .

La independencia de  $A$  y  $B$  implica

$$P(A|B) = P(A), \text{ si } P(B) \neq 0$$

$$P(B|A) = P(B), \text{ si } P(A) \neq 0$$



# Redes Bayesianas

## Independencia de Eventos

Tenemos: Suponiendo A y B son **independientes**:

$$P(B|A) = \frac{P(A \cap B)}{P(A)}$$

$$P(A \cap B) = P(A)P(B)$$

Prueba:

$$P(B|A) = \frac{P(A)P(B)}{P(A)} = P(B)$$

$$P(A|B) = \frac{P(A)P(B)}{P(B)} = P(A)$$

La independencia de A y B implica

$$\begin{aligned} P(A|B) &= P(A), \text{ si } P(B) \neq 0 \\ P(B|A) &= P(B), \text{ si } P(A) \neq 0 \end{aligned}$$



# Redes Bayesianas

## Independencia Condicional

### Definición

Dos eventos  $A$  y  $B$  son condicionalmente independientes dado un evento  $C$ , si y solo si

$$P(A \cap B | C) = P(A | C)P(B | C)$$

Notación:  $I(A, B | C)$ .

La independencia condicional de  $A$  y  $B$ , dado un evento  $C$ , implica:

$$\begin{aligned} P(A | C, B) &= P(A | C), \text{ si } P(B | C) \neq 0 \\ P(B | C, A) &= P(B | C), \text{ si } P(A | C) \neq 0 \end{aligned}$$



# Redes Bayesianas

## Independencia Condicional

Tenemos:

$$P(A \cap B|C) = P(A|C)P(B|C)$$

La independencia condicional de  $A$  y  $B$ , dado un evento  $C$ , implica

Prueba:

$$P(A|C, B) = \frac{P(A \cap B|C)}{P(B|C)} = \frac{P(A|C)P(B|C)}{P(B|C)} = P(A|C)$$

$$P(B|C, A) = \frac{P(A \cap B|C)}{P(A|C)} = \frac{P(A|C)P(B|C)}{P(A|C)} = P(B|C)$$

La independencia condicional de  $A$  y  $B$ , dado un evento  $C$ , implica:

$$P(A|C, B) = P(A|C), \text{ si } P(B|C) \neq 0$$

$$P(B|C, A) = P(B|C), \text{ si } P(A|C) \neq 0$$

# Redes Bayesianas

# Regla de Bayes

# La definición de Probabilidad Condicional

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \qquad P(B|A) = \frac{P(A \cap B)}{P(A)}$$

## Implica la Regla de la Cadena

$$P(A \cap B) = P(A|B)P(B)$$

$$P(A \cap B) = P(B|A)P(A)$$

## Regla de Bayes

$$P(B|A) = \frac{P(A|B)P(B)}{P(A)}$$



# Redes Bayesianas

## Regla de Bayes

Desde el punto de vista bayesiano, todas las probabilidades son condicionales porque casi siempre existe algún conocimiento previo o experiencia acerca de los sucesos.

$$P(B|A) = \frac{P(A \cap B)}{P(A)}$$



# Redes Bayesianas

## Regla de Bayes

### Ley de la Probabilidad Total

Para un suceso  $A$  y unas particiones  $B_1, \dots, B_k$ , mutuamente excluyentes y exhaustivos entre si:  $B_i \cap B_j = \emptyset$ , con  $i \neq j$ .


Excluyentes: Si no hay dos con resultados comunes.

Exhaustivos: Si debe ocurrir un  $B_i$ , entonces  $B_1 \cup B_2 \cup B_3 \cup \dots \cup B_k = S$

Si tomamos dos eventos  $B_i$  diferentes, su intersección da como resultado el conjunto vacío.

Adicionalmente, la unión de todos los eventos  $B_i$ , cubre el espacio de eventos, así:

$$\bigcup_{i=1}^n B_i = S$$



# Redes Bayesianas

# Regla de Bayes

## Ley de la Probabilidad Total

Para conocer el evento  $A$  a través de los eventos  $B_i$ , se tiene:

$$A = (A \cap B_1) \cup (A \cap B_2) \cup (A \cap B_3) \cup \dots \cup (A \cap B_{n-1}) \cup (A \cap B_n)$$

A se define como la unión de las intersecciones del evento A con los eventos  $B_i$ , así:

$$A = \bigcup_{i=1}^n (A \cap B_i)$$

Por Probabilidad Conjunta, se tiene que:  $P(A \cap B) = P(A/B)P(B)$

Y la probabilidad de A, como:  $P(A) = \sum_{i=1}^n P(A \cap B_i)$

Con  $k = n$

$$P(A) = \sum_{i=1}^k P(A|B_i)P(B_i)$$



# Redes Bayesianas

## Regla de Bayes

Permite obtener inferencias con mayor probabilidad asumiendo que se conoce información inicial. En términos de Bayes e inteligencia artificial, se define como:

$$\text{probabilidad } a \text{ posterior} \rightarrow P(X|E) = \frac{\overset{\text{probabilidad de verosimilitud}}{P(E|X)} \overset{\text{probabilidad } a \text{ priori}}{P(X)}}{\underset{\text{probabilidad conjunta de E}}{P(E)}}$$

Donde:

$X$ : es el conjunto de eventos que se desean conocer

$E$ : es el conjunto de evidencias



# Redes Bayesianas

## Regla de Bayes

Suponiendo que las particiones son sobre A:

Sea  $A_1, \dots, A_n$  una colección de  $k$  eventos mutuamente excluyentes y exhaustivos, con  $P(A_i) > 0$  para  $i = 1, 2, \dots, k$ . Entonces para cualquier otro evento  $B$  para el cual  $P(B) > 0$ ,

$$P(A_j|B) = \frac{P(A_j \cap B)}{P(B)} = \frac{P(B|A_j)P(A_j)}{\sum_{i=1}^k P(B|A_i)P(A_i)} \quad j = 1, 2, \dots, k$$

$P(B)$  es una constante que puede ser calculada como:  $P(B) = \sum_{i=1}^k P(B|A_i)P(A_i)$

$P(A_i)$  se puede estimar a partir del conjunto de entrenamiento (fracción de registros de entrenamiento que pertenecen a cada clase)

$P(B|A_i)$  es una tarea más difícil. Métodos:

- Clasificador Naive Bayes
- **Red Bayesiana**

# Redes Bayesianas

# Regla de Bayes

$P(B|A_i)$     Métodos para estimarlos:

- Clasificador Naive Bayes
- **Red Bayesiana**

**Clasificador Naive Bayes**, se asume que los atributos son condicionalmente independientes, dada una variable-clase  $y$ .

Redes Bayesianas, se tiene en cuenta la dependencia entre los atributos.







# Redes Bayesianas

## Regla de Bayes

### Reglas de la Probabilidad Total

Probabilidad Total Conjunta para una variable

$$P(C) = P(B \cap C) + P(B^c \cap C)$$

$$P(C) = P(B, C) + P(B^c, C)$$

Probabilidad Total Condicional para una variable

$$P(C) = P(C|B) P(B) + P(C|B^c) P(B^c)$$

Probabilidad Total Conjunta para dos variables

$$P(B, C) = P(A, B, C) + P(A^c, B, C)$$

$$P(B, C) = P(A \cap B \cap C) + P(A^c \cap B \cap C)$$

→ Regla de la Cadena

Probabilidad Total Condicional para dos variables

$$P(C|B) = P(C, B)/P(B) = P(C, A, B)/P(B) + P(C, A^c, B)/P(B)$$

$$= P(C, A|B) + P(C, A^c|B)$$

→ Definición de Probabilidad Condicional




# Redes Bayesianas

## Grafo Dirigido

### Definición

Un grafo dirigido o digrafo  $G$  es un par ordenado

$G := (V, A)$ , donde  $V$  es un conjunto cuyos elementos son llamados vértices.  $A \subset V \times V$  es un conjunto de pares ordenados de vértices llamados bordes dirigidos, arcos o flechas



$$V = \{V_1, V_2, V_3, V_4, V_5\}$$

$$E = \{(V_1, V_1), (V_1, V_4), \\ (V_2, V_1), (V_4, V_2), \\ (V_5, V_5)\}$$


$$\text{Cycle: } V_1 \rightarrow V_4 \rightarrow V_2$$

# Redes Bayesianas

## Grafo Acíclico Dirigido

## Definición

Un grafo dirigido acíclico digrafo (DAG) es un grafo dirigido sin ciclos dirigidos, es decir, para cualquier vértice  $V_j$ , no hay un camino dirigido que empiece en  $V_j$  y termina en  $V_j$ .






# Redes Bayesianas

## Algunas descripciones en la Teoría de Grafos

- $V_1$  y  $V_4$  son padres de  $V_2$ , pues  $(V_1, V_2) \in E$ ,  $(V_4, V_2) \in E$
- $V_5$ ,  $V_3$  y  $V_2$  son descendientes de  $V_1$
- $V_4$  y  $V_2$  son antepasados de  $V_3$  existen caminos dirigidos de estos vertices a  $V_3$
- $V_4$  y  $V_6$  no son descendientes de  $V_1$  no existen caminos dirigidos a estos vertices desde  $V_1$





# Redes Bayesianas

## Definición de una Red Bayesiana

Una Red Bayesiana es:

- ✿ Es un Grafo Acíclico Dirigido (DAG)  $G$ , que registra la relación de dependencia entre un conjunto de variables.
- ✿ Una tabla de probabilidades que asocia cada nodo a sus nodos padres inmediatos.
- ✿ Cada nodo del grafo representa una variable (El grafo está formado por un conjunto de variables proposicionales,  $V$ ).
- ✿ Un conjunto de relaciones binarias definidas sobre las variables de  $V$ ,  $E$ .
- ✿ Cada arco confirma la relación de dependencia entre el par de variables.
- ✿ Una distribución de probabilidad conjunta sobre las variables de  $V$ .
- ✿ DAG satisface la Condición de Markov.



# Redes Bayesianas

## La Condición de Markov

Definición:

Suponga que se tiene una distribución de probabilidad  $P$  de variables aleatorias en un conjunto  $V$ , y un DAG  $G = (V, E)$ . Se dice que  $(G, P)$  satisface la Condición de Markov si por cada variable  $X \in V$ ,  $\{X\}$  (el conjunto de los padres directos de  $X$ ), es condicionalmente independiente del conjunto de todos los otros nodos de la red - $ND_X$ - (o, lo que es lo mismo, separa condicionalmente a  $X$  de todo otro nodo  $Y$  de la red, que no sea  $X$ ), (salvo sus descendientes), dados sus padres - $PA_X$ .

$$I(\{X\}, ND_X | PA_X)$$


La definición implica que el nodo raíz  $X$ , el cual no tiene padres, es incondicionalmente independiente de los otros nodos de la red.



# Redes Bayesianas

## Ejemplo 1

Consideremos la red dada en la siguiente figura:



$$P(a_1) = 0.3; P(b_1/a_1) = 0.4; P(b_1/a_2) = 0.6; P(c_1/a_1) = 0.7; P(c_1/a_2) = 0.2$$

$$a_1 = A$$

$$a_2 = A^c$$

En el que las variables que aparecen son binarias, junto con la siguiente distribución de probabilidad conjunta:





# Redes Bayesianas

## Ejemplo 1

En el que las variables que aparecen son binarias, junto con la siguiente distribución de probabilidad conjunta:

$$P(a_1, b_1, c_1) = 0.084$$

$$P(a_1, b_2, c_1) = 0.126$$

$$P(a_2, b_1, c_1) = 0.084$$

$$P(a_2, b_1, c_2) = 0.336$$

$$P(a_1, b_1, c_2) = 0.036$$

$$P(a_1, b_2, c_2) = 0.054$$

$$P(a_2, b_2, c_1) = 0.056$$

$$P(a_2, b_2, c_2) = 0.224$$

Es esto una Red Bayesiana?

# Redes Bayesianas

## Ejemplo 1

## Es esto una Red Bayesiana?

Solución:

En este caso, la condición de independencia condicional se satisface si  $C$  y  $B$  son independientes dado su padre común  $A$ .

Se debe probar entonces, que:  $P(B|A, C) = P(B|A)$ .

Para lo anterior, se debe probar que:

$$P(b_1/a_1, c_1) = P(b_1/a_1)$$

$$P(b_2/a_1, c_1) = P(b_2/a_1)$$

$$P(b_1/a_1, c_2) = P(b_1/a_1)$$

$$P(b_2/a_1, c_2) = P(b_2/a_1)$$

$$P(b_1/a_2, c_1) = P(b_1/a_2)$$

$$P(b_2/a_2, c_1) = P(b_2/a_2)$$

$$P(b_1/a_2, c_2) = P(b_1/a_2)$$

$$P(b_2/a_2, c_2) = P(b_2/a_2)$$

# Redes Bayesianas

## Ejemplo 1

Es esto una Red Bayesiana?

$$P(B) = \sum_{i=1}^k P(B|A_i)P(A_i)$$

Solución:

A modo de ejemplo, comprobaríamos:

$$P(b_1/a_1, c_2) = P(b_1/a_1)$$

1.  $P(b_1/a_1, c_2)$
2.  $P(b_1/a_1)$

$$1. \quad P(\mathbf{b}_1|\mathbf{a}_1, \mathbf{c}_2) = \frac{P(b_1, a_1, c_2)}{P(a_1, c_2)} = \frac{P(a_1, b_1, c_2)}{P(a_1, c_2)} =$$

$$\frac{0,036}{P(a_1, b_1, c_2) + P(a_1, b_2, c_2)} = \frac{0,036}{0,036 + 0,054} = 0,4$$

# Redes Bayesianas

## Ejemplo 1

Solución:

$$P(B) = \sum_{i=1}^k P(B|A_i)P(A_i)$$

$$P(b_1/a_1, c_2) = P(b_1/a_1)$$

$$1. \quad P(b_1/a_1, c_2)$$

$$2. \quad P(b_1/a_1)$$

$$2. \quad P(b_1|a_1) = \frac{P(b_1, a_1)}{P(a_1)} = \frac{P(a_1, b_1, c_1) + P(a_1, b_1, c_2)}{P(a_1, b_1) + P(a_1, b_2)}$$

$$= \frac{P(a_1, b_1, c_1) + P(a_1, b_1, c_2)}{P(a_1, b_1, c_1) + P(a_1, b_1, c_2) + P(a_1, b_2, c_1) + P(a_1, b_2, c_2)}$$

$$= \frac{0,084 + 0,036}{0,084 + 0,036 + 0,126 + 0,054} = \frac{0,12}{0,3} = 0,4$$

Realizando las comprobaciones restantes, se vería que en este caso sí tenemos una Red Bayesiana!




# Redes Bayesianas

## Definición

Si se cumplen las condiciones de independencia condicional, a partir de las probabilidades condicionales, es posible calcular la distribución conjunta, así, por ejemplo:

Para un grafo G



$$P(B, C) = P(B).P(C|B)$$

$$P(B, C) = P(A, B, C) + P(A^c, B, C) =$$


$$P(A, B, C) = P(A).P(B|A).P(C|A, B)$$

$$P(A^c, B, C) = P(A^c).P(B|A^c).P(C|A^c, B)$$

# Redes Bayesianas


## Ejemplo 2

# Representación de Grafos



$$P(X, Y, Z) = ?$$

$$P(X, Y, Z) = P(X).P(Z|X).P(Y|X, Z)$$




$$P(X, Y, Z) = ?$$


# Redes Bayesianas

## Ejemplo 2

### Representación de Grafos



$$P(X, Y, Z) = ?$$



$$P(X, Y, Z) = ?$$

# Referencias

Material de apoyo de la semana registrados en SAVIO (Diapositivas):

Bayesian networks without tears: making Bayesian networks more accessible to the probabilistically unsophisticated. Eugene Charniak  
AI Magazine Volume 12 , Issue 4 (Winter 1991) Pages: 50 - 63 Year of Publication: 1991

Learning Bayesian Networks. Richard E. Neapolitan. Prentice Hall



# Gracias!

