

# Machine Learning

## Programa de Ingeniería de Sistemas

Tema: Regresión Lineal – Gradiente Descendente





# Regresión Lineal

## Aprendizaje

Para encontrar el conjunto de  $\theta$ 's que minimizan el error se plantea el siguiente problema de optimización:

$$\min_{\theta} J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2.$$

Para resolverlo, se puede optar por:

- ⊙ El método Analítico, haciendo uso de Ecuaciones Normales
- ⊙ El método del Gradiente Descendente

$$J(\theta) \quad \theta's \quad h(x^{(i)})'s \quad y^{(i)'}s$$



# Regresión Lineal

## Aprendizaje

### ✿ El método del Gradiente Descendente

- ✱ El método del Gradiente Descendente es un algoritmo de optimización que utiliza el valor del gradiente de la función a optimizar para dirigirse hacia un mínimo local.
- ✱ Es un método iterativo de primer orden (que contiene solo derivadas simples).
- ✱ Si la función a optimizar es convexa, este método siempre convergerá al óptimo local dada una correcta escogencia de parámetros.
- ✱ La intuición tras este método es que siendo el gradiente, el vector que apunta en la dirección de mayor crecimiento de la función a optimizar, es lógico entonces moverse en la dirección contraria a este, para alcanzar un óptimo local.



# Regresión Lineal


## Aprendizaje

### ✿ El método del Gradiente Descendente

Fórmula general:

$$\theta = \theta - \alpha \frac{\partial J(\theta)}{\partial \theta}$$

Captura la intuición de moverse en la dirección contraria al gradiente, al anteponer un signo negativo a este.





# Regresión Lineal

## Aprendizaje

### ✿ El método del Gradiente Descendente

Para poder aplicarlo, necesitamos conocer el gradiente de la función a optimizar

$$\left( \frac{\partial J(\theta)}{\partial \theta} \right)$$

# Regresión Lineal

## Aprendizaje

### ✿ El método del Gradiente Descendente

Entonces, tenemos que la función de error en la Regresión Lineal es:

$$J(\theta) = \frac{1}{2N} \sum_{n=1}^N (h(x_n) - y_n)^2$$

Nótese que ahora la sumatoria está multiplicada por  $\frac{1}{2N}$ . Este es un pequeño artificio para facilitar la derivación de la regla de actualización de Gradiente Descendente, y no afecta el resultado.



# Regresión Lineal

## Aprendizaje

### ✿ El método del Gradiente Descendente

El gradiente entonces es:

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{N} \sum_{n=1}^N (h(x_n) - y_n) x_{nj}$$

- j es el subíndice de los  $\theta$ 's
- n es el subíndice de la entrada en la matriz  $\mathcal{X}$  (el registro n en la matriz  $\mathcal{X}$ )
- $x_{nj}$  es un valor en matriz  $\mathcal{X}$  ubicado en la fila n, columna j (fila n de N registros, columna j de k parámetros:  $\theta_0, \theta_1, \theta_2 \dots \theta_k$ )



# Regresión Lineal

## Aprendizaje

### ✿ El método del Gradiente Descendente

Por lo anterior, la regla de actualización de Gradiente Descendente sería:

$$\theta_j = \theta_j - \alpha \frac{1}{N} \sum_{n=1}^N (h(X_n) - Y_n) X_{nj}$$

Dónde:

$h(X_n)$  en Regresión Lineal es  $\theta^T \mathcal{X}$

$h(X_n)$  en Regresión Logística es  $\frac{1}{1 + e^{-\theta^T x}}$





# Regresión Lineal

## Aprendizaje

### ✿ El método del Gradiente Descendente

Teniendo la regla, el algoritmo sería el siguiente:

1. Hacer, para toda  $j$
2. La función...

$$\theta_j = \theta_j - \alpha \frac{1}{N} \sum_{n=1}^N (h(X_n) - Y_n) X_{nj}$$

3. Mientras que  $\alpha \left\| \frac{\partial J(\theta)}{\partial \theta_j} \right\| > \epsilon$

Nota: La actualización de los  $\theta_j$  debe ser simultánea (primero se calculan todos los  $\theta_j$  y luego se reemplazan los anteriores).



# Regresión Lineal

## Aprendizaje

### ✿ El método del Gradiente Descendente

Mientras que  $\alpha \left\| \frac{\partial J(\theta)}{\partial \theta_j} \right\| > \epsilon$

$\alpha \left\| \frac{\partial J(\theta)}{\partial \theta_j} \right\| > \epsilon = 0.001$  (por ejemplo)



# Regresión Lineal

## Aprendizaje

### ✿ El método del Gradiente Descendente

La regla de actualización del Gradiente Descendente sería:

$$\theta_j = \theta_j - \alpha \frac{1}{N} \sum_{n=1}^N \left[ \left( \frac{1}{1 + e^{-\theta^T x_n}} - y_n \right) X_{nj} \right]$$

El vector  $\vec{\theta}$  es igual a  $[\theta_0, \theta_1, \theta_2]$

El vector  $\vec{\theta}$  inicialmente tiene los valores en cero:  $[0, 0, 0]$

El subíndice  $j$  representa la cantidad de  $\theta$ 's

$\alpha$  vale 0.1 (sugerencia)



# Regresión Lineal

## Aprendizaje

### ✿ El método del Gradiente Descendente

Cálculo de  $\theta_0$  :

$$\vec{\theta} = [\theta_0, \theta_1, \theta_2]$$

Suponiendo que se cuenta con una matriz  $X$ , con  $m$  columnas (una por cada  $\theta$ )

$$X = \begin{matrix} & \overbrace{\hspace{1.5cm}}^m & & \\ \begin{pmatrix} 1 \\ \vdots \\ 1 \\ \vdots \\ 1 \end{pmatrix} & \begin{pmatrix} \vdots \\ x_{n1} \\ \vdots \end{pmatrix} & \begin{pmatrix} \vdots \\ x_{n2} \\ \vdots \end{pmatrix} \end{matrix} \quad \begin{matrix} \gamma \\ \begin{pmatrix} \vdots \\ y_n \\ \vdots \end{pmatrix} \end{matrix} \quad \left. \vphantom{\begin{pmatrix} \vdots \\ y_n \\ \vdots \end{pmatrix}} \right\} N \text{ registros}$$

*Note: In the original image, an arrow points from the label  $x_{n0}$  to the '1' in the third row of the first column of matrix X.*



# Regresión Lineal

## Aprendizaje

### ✿ El método del Gradiente Descendente

Primera interacción de  $\theta_0$ :

$$\theta_0 = \theta_0 - \alpha \frac{1}{N} \sum_{n=1}^N \left[ \left( \frac{1}{1 + e^{-\theta^T x_n}} - y_n \right) X_{n0} \right]$$

En la sumatoria, en el término  $1 + e^{-\theta^T x_n}$  es conveniente:

- ⊙ Realizar la operación  $-\theta^T x_n$  dentro del ciclo, pero justo antes de hacer la operación  $\frac{1}{1 + e^{-\theta^T x_n}}$  cada vez!
- ⊙ Para este primer caso sería así:

# Regresión Lineal

## Aprendizaje

### ✿ El método del Gradiente Descendente

- ⊙ Para este primer caso sería así:  
Vector  $\theta^T$  \* la fila 1 de la matriz  $\mathcal{X}$  ( $n = 1$ ).

$$\theta^T x_1 = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}_{3 \times 1} * x_1$$

$$\theta^T x_1 = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}_{3 \times 1} * \begin{pmatrix} x_{10} & x_{11} & x_{12} \end{pmatrix}_{1 \times 3}$$



# Regresión Lineal

## Aprendizaje

### ✿ El método del Gradiente Descendente

- ⦿ Para este primer caso sería así:  
Vector  $\theta^T$  \* la fila 1 de la matriz  $\mathcal{X}$  ( $n = 1$ ).

$$\theta^T x_1 = \theta_0 x_{10} + \theta_1 x_{11} + \theta_2 x_{12}$$

$$\theta^T x_1 = 1 + \theta_1 x_{11} + \theta_2 x_{12}$$

$$\theta^T x_1 = \text{da un número (que llamaremos } s_1)$$

# Regresión Lineal

## Aprendizaje

### ✿ El método del Gradiente Descendente

- Para este segundo caso sería así:  
Vector  $\theta^T$  \* la fila 2 de la matriz  $X$  ( $n = 1$ ).

$$\theta^T x_2 = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}_{3 \times 1} * x_2$$

$$\theta^T x_2 = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}_{3 \times 1} * \begin{pmatrix} x_{20} & x_{21} & x_{22} \end{pmatrix}_{1 \times 3}$$



# Regresión Lineal

## Aprendizaje

### ✿ El método del Gradiente Descendente

- ⊙ Para este segundo caso sería así:  
Vector  $\theta^T$  \* la fila 2 de la matriz  $\mathcal{X}$  ( $n = 2$ ).

$$\theta^T x_2 = \theta_0 x_{20} + \theta_1 x_{21} + \theta_2 x_{22}$$

$$\theta^T x_2 = 1 + \theta_1 x_{21} + \theta_2 x_{22}$$

$$\theta^T x_2 = \text{da un número (que llamaremos } s_1)$$

Etc., hasta llegar a  $N$  registros.

# Regresión Lineal

## Aprendizaje

### ✿ El método del Gradiente Descendente

- Al valor obtenido al evaluar la expresión  $\frac{1}{1 + e^{-\theta^T x_1}}$ , se le resta el valor almacenado en el vector  $\vec{Y}$ , en la fila 1, de N-filas en la matriz, así:

$$\frac{1}{1 + e^{-\theta^T x_1}} - Y_1 \quad \bigg| \quad \frac{1}{1 + e^{-s_1}} - Y_1$$

- El resultado de la operación anterior, es multiplicado por su respectiva  $X_{n0}$ , que en este caso sería:

$$X_{n0} = X_{10}$$



# Regresión Lineal

## Aprendizaje

### ✿ El método del Gradiente Descendente

$$X_{n0} = X_{10}$$

Es uno (1) porque se está evaluando ahora mismo la fila 1 de la matriz X.

Es cero (0) en la posición, porque se está intentando calcular el valor de  $\theta_0$

En este caso, el valor de  $X_{10}$  es igual a 1. (Columna insertada en la primera columna de la matriz X.

# Regresión Lineal

# Aprendizaje

## El método del Gradiente Descendente

Una vez se obtenga el cálculo de la sumatoria, este resultado es multiplicado por  $\alpha \frac{1}{N}$ .

El resultado de toda la operación debe ser guardado en una variable porque esta variable es utilizada para controlar el ciclo (para el cálculo del valor de cada  $\theta$ ).

$$\alpha \left\| \frac{\partial J(\theta)}{\partial \theta_j} \right\| > \epsilon$$

Nota: La actualización de los  $\theta_j$  debe ser simultánea (primero se calculan todos los  $\theta_j$  y luego se reemplazan los anteriores).





# Regresión Lineal

## Aprendizaje

### ✿ El método del Gradiente Descendente

$\alpha$  se conoce como la tasa de aprendizaje (el tamaño de los pasos que da el algoritmo), y debe ser escogido cuidadosamente puesto que:

- \* Un valor muy alto puede hacer que el algoritmo diverja
- \* Un valor muy pequeño puede demorar demasiado tiempo en converger.





# Regresión Lineal

## Aprendizaje

### ✿ El método del Gradiente Descendente

- ✱ Al usar Gradiente Descendente para entrenar un modelo de Regresión Lineal, es conveniente escalar y normalizar las entradas.
- ✱ Escalando y normalizando usualmente acelera el proceso de aprendizaje, al poder usarse una tasa de aprendizaje mayor.
- ✱ Una forma de normalizar la media de los datos, que significa llevar  $\mu = 0$ , y llevarlos aproximadamente al intervalo  $[-1, 1]$ , es la siguiente:

$$x_i = \frac{x_i - \mu_i}{\max_i - \min_i}$$

para cada variable de entrada  $x$ .

# Regresión Lineal

## Aprendizaje

### ✿ El método del Gradiente Descendente

Ejemplo de normalización de datos:

$\mathcal{X}$  = Edad [20, 30, 40, 50, 60]

$$x_i = \frac{x_i - \mu_i}{\max_i - \min_i}$$

$$x_1 = \frac{20 - 40}{60 - 20} = \frac{-20}{40} = \frac{-1}{2}$$

$$x_2 = \frac{30 - 40}{60 - 20} = \frac{-10}{40} = \frac{-1}{4}$$



Universidad  
Tecnológica  
de Bolívar  
CARTAGENA DE INDIAS



# Actividad Extra-clase

## Taller

No aplica aún!



# Referencias

Material de apoyo de la semana registrados en SAVIO.

# Gracias!

